

Diseño de Redes Neuronales Confiables

Justicia e Incertidumbre en la Concesión de Crédito

Taller B4-T1 — Home Credit Default Risk

Grupo 7

Instituto BME / Daniel Gallego Sánchez , Marco Corpa Criado , Javier Fernández Guerra

23 de junio de 2026

Índice

1. Introducción y Objetivo	2
2. Análisis Exploratorio de Datos	2
2.1. Dataset y features seleccionadas	2
2.2. Desbalanceo de clases	2
2.3. Valores ausentes y máscaras	3
2.4. Transformación log1p	3
2.5. Poder predictivo	4
2.6. Disparidad de género	4
2.7. Interacciones no lineales	5
3. Preprocesado y Pipeline de Datos	5
4. Arquitectura del Modelo	5
4.1. Justificación del tipo de red	5
4.2. Capas custom	6
4.2.1. DebtRatioLayer	6
4.2.2. ExtSourceLayer	6
4.3. Progresión de modelos	6
5. Aprendizaje Justo — FAIR Loss	8
5.1. Formulación	8
5.2. Curva de Pareto multi-semilla	9
6. Incertidumbre — MC Dropout	9
7. Análisis de Features Extendidas	11
7.1. Motivación	11
7.2. Pipeline extendido (42 features)	11
7.3. Resultados	11
8. Conclusiones	12

1. Introducción y Objetivo

El presente trabajo aborda el diseño, entrenamiento y auditoría de modelos de clasificación neuronal para la concesión de créditos. El dataset utilizado es el **Home Credit Default Risk** (Kaggle, 307 507 solicitudes), cuyo objetivo es predecir si un solicitante tendrá dificultades de pago (**TARGET=1**, $\approx 8\%$) o no (**TARGET=0**, $\approx 92\%$).

Los objetivos específicos del trabajo son:

1. **Arquitectura customizada:** implementar capas Keras con restricciones de dominio financiero.
2. **Aprendizaje Justo (FAIR Loss):** diseñar una función de coste que penalice la dependencia estadística entre las predicciones y el género del solicitante.
3. **Progresión de arquitecturas:** explorar modelos de complejidad creciente y justificar cada elección.
4. **Incertidumbre:** cuantificar la varianza de las predicciones y analizar su relación con la calidad de los datos de entrada.

2. Análisis Exploratorio de Datos

2.1. Dataset y features seleccionadas

Se seleccionaron las 9 columnas del enunciado: **TARGET**, **CODE_GENDER**, **AMT_INCOME_TOTAL**, **AMT_CREDIT**, **AMT_ANNUITY**, **DAYS_BIRTH**, **EXT_SOURCE_1/2/3**.

2.2. Desbalanceo de clases




Figura 1: El 91.9 % de los solicitantes pagaron a tiempo; solo el 8.1 % presentó dificultades de pago (razón 11.4:1).

El fuerte desbalanceo tiene consecuencias directas: la métrica de evaluación es **AUC-ROC** (no *accuracy*) y se aplican **class weights** durante el entrenamiento (clase 1 ponderada $\approx 11.4\times$).

2.3. Valores ausentes y máscaras




Figura 2: EXT_SOURCE_1 presenta el mayor porcentaje de nulos (56.4%), seguido de EXT_SOURCE_3 (19.8%).

Los nulos se tratan con imputación por la mediana (calculada solo en train) y con **máscaras binarias** (EXT_SOURCE*_MISSING) que señalan si el valor original estaba ausente. Estas máscaras son la materia prima del análisis de incertidumbre (Sección 6).

2.4. Transformación log1p




Figura 3: Distribuciones antes y después de $\log(1 + x)$. La transformación elimina la cola asimétrica extrema sin pérdida de información.

2.5. Poder predictivo




Figura 4: Las tres fuentes externas muestran clara separación entre clases: quienes impagan tienen scores más bajos.




Figura 5: Tasa de impago por decil. `EXT_SOURCE_*` son monótonas decrecientes. `AMT_CREDIT` y `AMT_ANNUITY` muestran una **joroba**: los créditos medios tienen más impago que los extremos, lo que requiere al menos dos capas ocultas.

2.6. Disparidad de género




Figura 6: Los hombres tienen tasa de impago del 10.1 % frente al 7.0 % de las mujeres. Las 4 filas con `CODE_GENDER=XNA` fueron eliminadas.

2.7. Interacciones no lineales




Figura 7: El riesgo máximo (rojo) se concentra donde **ambas** fuentes son bajas simultáneamente — efecto de interacción no capturables con una sola capa oculta.

3. Preprocesado y Pipeline de Datos

Cuadro 1: Transformaciones aplicadas y su justificación.

Variable(s)	Transformación	Justificación
AMT_INCOME_TOTAL/CREDIT/ANNUITY	$\log(1 + x)$	Colas asimétricas
DAYS_BIRTH	$ x /365$	Edad en años positiva
CODE_GENDER	M $\rightarrow$ 0, F $\rightarrow$ 1; XNA eliminado	Binaria limpia
EXT_SOURCE_*	Imputación mediana (train)	20–56 % nulos
EXT_SOURCE_*_MISSING	Máscara binaria	Señal + incertidumbre
DEBT_RATIO	AMT_ANNUITY / AMT_INCOME	Dominio financiero
Variables continuas	StandardScaler (train)	Gradiente estable

Split estratificado **60/20/20**: train 184 504, val 61 501, test 61 502, con tasa de impago uniforme 8.07 % en los tres conjuntos.

4. Arquitectura del Modelo

4.1. Justificación del tipo de red

Se eligió **MLP denso** porque los datos son tabulares sin estructura espacial ni temporal. RNN, CNN y Transformer son descartados por requerir estructura secuencial o espacial que estos datos no tienen.

4.2. Capas custom

4.2.1. DebtRatioLayer

$$f(x) = \sigma(\alpha \cdot (x - \theta)), \quad \alpha \geq 0 \quad (1)$$

Inicializada con $\alpha = 10$ y $\theta = 0,35$ (referencia regulatoria del 35 %). Justificación: un ratio de 0.8 y uno de 1.5 son equivalentes (“imposible pagar”); la sigmoide aplana esa diferencia. Tras el entrenamiento, θ convergió a 0.16, revelando que el umbral real en estos datos es inferior al regulatorio.

4.2.2. ExtSourceLayer

$$g(\mathbf{s}) = \sigma(w_1 s_1 + w_2 s_2 + w_3 s_3 + b), \quad w_i \geq 0 \quad (2)$$


La restricción $w_i \geq 0$ garantiza monotonía negativa con el impago. Los pesos aprendidos ($w_1 = 0,44$, $w_2 = w_3 = 0,61$) son **auditables**: el modelo asigna menos peso a EXT_SOURCE_1, coherente con su mayor tasa de nulos (56 %).

4.3. Progresión de modelos


Cuadro 2: Comparativa de modelos con 12 features (AUC en test, class weights 11.4×).

Modelo	Arquitectura	AUC val	AUC test	Paráms
M0	Reg. Logística	0.7275	0.7335	13
M1	Dense 64, ReLU	0.7416	0.7449	897
M2	Dense 128→64	0.7411	0.7447	9985
M3	M2 + Dropout(0.3, 0.2)	0.7424	0.7452	9985
M4	M3 + DebtRatioLayer	0.7424	0.7449	9988
M5	M4 + ReduceLR	0.7428	0.7449	9988
M6	M5 + ExtSourceLayer	0.7421	0.7451	9991
M3 largo	M3 + ReduceLR + 500 épocas	0.7419	0.7457	9985


Hallazgo del entrenamiento extendido. Se entrenaron M2*, M3 y M6 hasta 500 épocas con EarlyStopping(patience=50) y ReduceLROnPlateau. M2* sin regularización presenta overfitting severo desde la época 9 (AUC train ≈ 0.76 vs val ≈ 0.74). M3 con Dropout alcanza el mejor AUC (0.7457). Las capas custom no mejoran el AUC bruto en ninguna configuración, confirmando que su valor es regulatorio e interpretativo.



(a) M0 — Reg. Logística



(b) M3 — MLP + Dropout



(c) M6 — Dual Custom

Figura 8: Curvas de entrenamiento representativas.




Figura 9: Arquitectura M6 (Dual Custom + Dropout). Las dos ramas custom se concatenan con la salida densa antes de la neurona final.

5. Aprendizaje Justo — FAIR Loss

5.1. Formulación

$$\mathcal{L}_{\text{fair}} = \underbrace{\text{BCE}(y, \hat{y})}_{\text{clasificación}} + \lambda \cdot \underbrace{\left| \mathbb{E}[\hat{y} \mid G = M] - \mathbb{E}[\hat{y} \mid G = F] \right|}_{\text{Paridad Demográfica}} \quad (3)$$

La **Paridad Demográfica (DP)** fue elegida frente a Equalized Odds (requiere y_{true} en el cálculo, complica el grafo), Mutual Information (no diferenciable) y correlación (solo lineal). DP es diferenciable, solo requiere $\hat{y}$ y G , y es el estándar regulatorio de la Directiva Europea de IA y la ECOA.

5.2. Curva de Pareto multi-semilla

Cada valor de λ se entrenó con **3 semillas** (42, 123, 7) para cuantificar la varianza de inicialización.




Figura 10: Curva de Pareto con barras de error ($\pm$ std entre semillas). La anomalía en $\lambda = 1,0$ es estructural: alta sensibilidad a la inicialización cuando BCE y DP tienen gradientes de peso similar.

Cuadro 3: Resultados Pareto multi-semilla (media $\pm$ std, evaluación en test).

λ	AUC	$\pm$ std	DP Gap	$\pm$ std	$\hat{p}(M)$	$\hat{p}(F)$	Reduc. DP
0.0	0.7465	0.0002	0.0295	0.0004	0.0994	0.0699	0.0 %
0.1	0.7438	0.0004	0.0084	0.0015	0.0837	0.0753	71.6 %
0.5	0.7425	0.0005	0.0051	0.0019	0.0831	0.0780	82.9 %
1.0	0.7417	0.0006	0.0028	0.0020	0.0778	0.0750	90.5 %
2.0	0.7396	0.0007	0.0035	0.0013	0.0768	0.0733	88.1 %
5.0	0.7351	0.0003	0.0014	0.0008	0.0732	0.0718	95.1 %

Modelo recomendado: $\lambda = 1,0$. Reduce el DP Gap un **90.5 %** (de 0.0295 a 0.0028) sacrificando solo 0.005 puntos de AUC. La curva no es perfectamente monótona por varianza estructural del optimizador SGD cuando los objetivos compiten con gradientes de peso similar — comportamiento conocido en la literatura de fairness para redes neuronales.

6. Incertidumbre — MC Dropout

Se utiliza **Monte Carlo Dropout** (Gal & Ghahramani, 2016): Dropout activo en inferencia, $N = 100$ pasadas por muestra:

$$\hat{\sigma}_i^2 = \frac{1}{N} \sum_{t=1}^N (\hat{y}_i^{(t)} - \bar{y}_i)^2 \quad (4)$$

Elegido frente a Redes Bayesianas (rediseño completo) y Deep Ensembles (N modelos $\times$ 6 lambdas = inviable). M6 ya tiene Dropout: coste de rediseño cero.




Figura 11: M6 base (izq.): varianza similar entre clases, no reconoce dificultad. FAIR $\lambda = 1$ (dcha.): varianza $2.5\times$ mayor en impagos.




Figura 12: FAIR muestra varianza creciente con el número de fuentes externas imputadas (+79 % con las tres ausentes). M6 base: plano.

Cuadro 4: Métricas de incertidumbre ($N = 100$ pasadas MC Dropout, test).

Métrica	M6 base	FAIR $\lambda = 1,0$
AUC puntual	0.7451	0.7424
AUC MC-mean	0.7455	0.7428
Var. media TARGET=0	0.001422	0.000123
Var. media TARGET=1	0.001306	0.000301
Ratio var(T=1)/var(T=0)	0.92 (<i>peor</i>)	2.45 (<i>mejor</i>)
Var. 0 EXT_SOURCE ausentes	0.001472	0.000134
Var. 3 EXT_SOURCE ausentes	0.001414	0.000241 (+79 %)

7. Análisis de Features Extendidas

7.1. Motivación

El techo de 0.745 AUC con 12 features planteaba dos hipótesis: (a) limitación de arquitectura, o (b) limitación de información. El entrenamiento extendido (hasta 500 épocas) descartó (a). Se analizaron las 122 columnas del dataset con **correlación de Spearman** y **d de Cohen** para seleccionar features adicionales.

7.2. Pipeline extendido (42 features)

Las features se seleccionaron por Spearman > 0.04 o d de Cohen > 0.10 . Las categóricas usan **target encoding con smoothing** para variables de alta cardinalidad (ORGANIZATION_TYPE, 58 categorías) y **one-hot** para las de baja cardinalidad (≤ 6 categorías):

Cuadro 5: Features adicionales más relevantes del pipeline extendido.

Variable	Encoding	Spearman / Cohen d
NAME_INCOME_TYPE	Target encoding	std tasa = 0.159
NAME_FAMILY_STATUS	One-hot (6 cat.)	std tasa = 0.037
NAME_EDUCATION_TYPE	One-hot (5 cat.)	std tasa = 0.036
REGION_RATING_CLIENT_W_CITY	Escalar	Spearman = 0.061
DAYS_LAST_PHONE_CHANGE	$ x $ + Escalar	Spearman = 0.055
DAYS_EMPLOYED	Outlier 365243→NaN	Spearman = 0.045
OCCUPATION_TYPE	Target encoding	std tasa = 0.030
ORGANIZATION_TYPE	Target encoding	58 categorías

7.3. Resultados




Figura 13: Comparativa AUC test con 12 vs 42 features. Los colores oscuros corresponden a los modelos extendidos.

Cuadro 6: Impacto de ampliar las features de 12 a 42 (AUC test).

Modelo	12 features	42 features	Δ AUC
M0 — Reg. Logística	0.7335	0.7501	+0.0166
M3 — MLP + Dropout	0.7457	0.7555	+0.0098
M6 — Dual Custom	0.7451	0.7550	+0.0099

El salto de 12 a 42 features produce $\approx +0.01$ AUC en los MLP y +0.017 en la regresión logística. Superar 0.80 con MLPs tabulares requeriría incorporar las tablas de historial de crédito del dataset o modelos basados en árboles (XGBoost, LightGBM), que son el estándar empírico para datos tabulares en competencias Kaggle.

8. Conclusiones

Cuadro 7: Resumen comparativo del sistema completo.

Métrica	M6 (12 feat.)	FAIR $\lambda = 1,0$	M3 (42 feat.)
AUC-ROC (test)	0.7451	0.7417	0.7555
DP Gap	0.0295	0.0028	—
Reduc. DP	—	90.5 %	—
Ratio $\text{var}(T=1)/\text{var}(T=0)$	0.92	2.48	—

- 1. El techo de AUC era de información, no de arquitectura.** El entrenamiento extendido confirma que 0.745 no se debe a falta de convergencia. Ampliar a 42 features produce +0.01 AUC. La señal adicional existe en el dataset y es explotable.
- 2. Dropout es el componente más efectivo.** M3 con Dropout supera a M2* sin él en todas las configuraciones. Las capas custom no mejoran el AUC bruto pero son auditables: los pesos de `ExtSourceLayer` reflejan coherentemente la calidad de cada fuente externa.
- 3. FAIR Loss con $\lambda = 1,0$ es el óptimo de Pareto.** Reduce el DP Gap un 90.5 % sacrificando 0.005 AUC. La curva no es monótona por varianza de inicialización cuando los gradientes de fairness y clasificación compiten con peso similar, efecto cuantificado por el experimento multi-semilla.
- 4. El modelo FAIR tiene mejor calibración de incertidumbre.** Es $2.5\times$ más incierto en impagos que en buenos pagadores, y aumenta su varianza monotónicamente cuando faltan fuentes externas (+73 % con las tres imputadas). El modelo base muestra el comportamiento opuesto en ambas dimensiones.