

Diseño de Redes Neuronales Confiables

Justicia e Incertidumbre en la Concesión de Crédito

Taller B4-T1 — Home Credit Default Risk

Grupo 7

Instituto BME / Daniel Gallego Sánchez , Marco Corpa Criado , Javier Fernández Guerra

22 de junio de 2026

Índice

1. Introducción y Objetivo	3
2. Análisis Exploratorio de Datos (EDA)	3
2.1. Dataset y features seleccionadas	3
2.2. Desbalanceo de clases	3
2.3. Valores ausentes	4
2.4. Variables financieras: asimetría y transformación	4
2.5. Poder predictivo de las variables	5
2.6. Disparidad de género	6
2.7. Interacciones no lineales: hexbin	6
3. Preprocesado y Pipeline de Datos	7
3.1. Decisiones de transformación	7
3.2. Partición de datos	7
4. Arquitectura del Modelo	8
4.1. Justificación del tipo de red	8
4.2. Función de activación y función de coste	8
4.3. Capas custom	8
4.3.1. DebtRatioLayer	8
4.3.2. ExtSourceLayer	8
4.4. Progresión de modelos	9
5. Aprendizaje Justo — FAIR Loss	10
5.1. Formulación	10
5.2. Justificación de la métrica de equidad	11
5.3. Curva de Pareto	11
6. Incertidumbre — MC Dropout	12
6.1. Método seleccionado	12
6.2. Distribución de incertidumbre por clase	12
6.3. Incertidumbre vs calidad de EXT_SOURCE	13
6.4. Resultados	13

1. Introducción y Objetivo

El presente trabajo aborda el diseño, entrenamiento y auditoría de modelos de clasificación neuronal para la concesión de créditos. El dataset utilizado es el **Home Credit Default Risk** (Kaggle, 307 507 solicitudes), cuyo objetivo es predecir si un solicitante tendrá dificultades de pago ($TARGET=1$, $\approx 8\%$) o no ($TARGET=0$, $\approx 92\%$).

Los objetivos específicos del trabajo son:

1. **Arquitectura customizada**: implementar capas Keras con restricciones de dominio financiero.
2. **Aprendizaje Justo (FAIR Loss)**: diseñar una función de coste que penalice la dependencia estadística entre las predicciones y el género del solicitante ($CODE_GENDER$).
3. **AutoML**: explorar la progresión de arquitecturas y justificar cada elección.
4. **Incertidumbre**: cuantificar la varianza de las predicciones y analizar su relación con la calidad de los datos de entrada.

2. Análisis Exploratorio de Datos (EDA)

2.1. Dataset y features seleccionadas

Se seleccionaron las 9 columnas más relevantes según el enunciado: $TARGET$, $CODE_GENDER$, AMT_INCOME_TOTAL , AMT_CREDIT , $AMT_ANNUITY$, $DAYS_BIRTH$, $EXT_SOURCE_1/2/3$.

2.2. Desbalanceo de clases




Figura 1: Distribución de la variable objetivo. El 91.9 % de los solicitantes pagaron a tiempo; solo el 8.1 % presentó dificultades de pago.

El fuerte desbalanceo (razón 11.4:1) tiene consecuencias directas en el diseño del modelo:

- La métrica de evaluación es **AUC-ROC**, no *accuracy*: un modelo que prediga siempre clase 0 obtendría 91.9 % de *accuracy* sin ninguna utilidad.
- Se utilizan **class weights** durante el entrenamiento (clase 1 ponderada $\approx 11.4\times$ más que la clase 0) para que el gradiente no ignore la clase minoritaria.

2.3. Valores ausentes




Figura 2: Porcentaje de valores ausentes por variable. `EXT_SOURCE_1` presenta el mayor hueco (56.4 %), seguido de `EXT_SOURCE_3` (19.8 %).

La distribución de nulos motiva dos decisiones de diseño:

1. **Imputación por la mediana** (calculada exclusivamente sobre el conjunto de entrenamiento para evitar fuga de datos).
2. Creación de **features de máscara binaria** (`EXT_SOURCE_*_MISSING`) que indican si el valor original estaba ausente. Estas features actúan como señal predictiva adicional y son la materia prima del análisis de incertidumbre (Sección 6).

2.4. Variables financieras: asimetría y transformación




Figura 3: Distribuciones antes (fila superior) y después (fila inferior) de aplicar $\log(1+x)$. La transformación elimina la cola asimétrica extrema (outlier de `AMT_INCOME_TOTAL` $\approx 1,17 \times 10^8$) sin pérdida de información.

La transformación $\log(1+x)$ se aplica a las tres variables monetarias (`AMT_INCOME_TOTAL`, `AMT_CREDIT`, `AMT_ANNUITY`) antes del escalado estándar. La justificación es doble: (1) com-

prime colas largas que dominarían el gradiente durante el entrenamiento, y (2) linealiza relaciones log-proporcionales habituales en datos financieros.

2.5. Poder predictivo de las variables




Figura 4: Distribución de EXT_SOURCE_1/2/3 por clase. Las distribuciones están claramente separadas: los solicitantes con impago tienen scores externos más bajos.




Figura 5: Tasa de impago por decil de cada variable continua. Las tres fuentes externas muestran una relación **monotóna decreciente** fuerte: el modelo necesita capturar esta señal. AMT_CREDIT y AMT_ANNUITY muestran una **joroba** (máximo en deciles intermedios), lo que implica que una sola capa oculta no puede capturar esta no-linealidad.

2.6. Disparidad de género




Figura 6: Tasa de impago por género. Los hombres (10.1 %) presentan mayor tasa que las mujeres (7.0 %). Las 4 filas con `CODE_GENDER=XNA` fueron eliminadas.

Esta disparidad de base motiva la introducción de la FAIR Loss (Sección 5): si el modelo optimiza solo AUC, aprenderá y amplificará esta diferencia, lo que constituye discriminación estadística en el sentido regulatorio.

2.7. Interacciones no lineales: hexbin




Figura 7: Hexbin de tasa de impago en el espacio $\text{EXT_SOURCE_2} \times \text{EXT_SOURCE_3}$. La zona de máximo riesgo (rojo oscuro) se concentra en la esquina inferior izquierda, donde **ambas** fuentes son bajas simultáneamente. Este efecto de interacción no es capturable con una sola capa oculta.

3. Preprocesado y Pipeline de Datos

3.1. Decisiones de transformación

Cuadro 1: Resumen de transformaciones aplicadas y su justificación.

Variable(s)	Transformación	Justificación
AMT_INCOME_TOTAL	$\log(1 + x)$	Cola asimétrica extrema ($\text{máx} = 1,17 \times 10^8$)
AMT_CREDIT	$\log(1 + x)$	Mismo patrón; joroba en deciles
AMT_ANNUITY	$\log(1 + x)$	Alta correlación con AMT_CREDIT
DAYS_BIRTH	$ x /365$	Convertir días negativos a edad en años
CODE_GENDER	M $\rightarrow$ 0, F $\rightarrow$ 1	Codificación binaria; XNA eliminado
EXT_SOURCE_*	Imputación mediana (train)	20–56 % nulos; sin fuga
EXT_SOURCE_*_MISSING	Máscara binaria nueva	Señal adicional + base para incertidumbre
DEBT_RATIO	AMT_ANNUITY/AMT_INCOME	Feature de dominio financiero (clip a 3.0)
Variables continuas	StandardScaler (train)	Gradiente estable; no aplicado a binarias

3.2. Partición de datos

Se realizó una partición estratificada **60/20/20** (train/val/test) manteniendo la proporción de impagos en los tres conjuntos (8.07 %):

Cuadro 2: Tamaños de los conjuntos tras el split estratificado.

Conjunto	Muestras	TARGET=1	Tasa impago
Train	184 504	14 889	8.07 %
Validación	61 501	4 963	8.07 %
Test	61 502	4 963	8.07 %
Total	307 507	24 815	8.07 %

El conjunto de **test permanece intocado** hasta la evaluación final. La validación se utiliza exclusivamente para el *early stopping* y la selección de hiperparámetros.

4. Arquitectura del Modelo

4.1. Justificación del tipo de red

Cuadro 3: Comparativa de familias de redes neuronales para este problema.

Tipo	Requiere	Decisión
RNN/LSTM	Orden temporal entre muestras o features	Descartado : cada fila es un solicitante independiente
CNN	Estructura espacial/local entre features	Descartado : no hay vecindad entre columnas
Transformer	Secuencias con atención	Descartado : sobreingeniería para 12 features tabulares
MLP denso	–	Seleccionado : estándar empírico para datos tabulares

4.2. Función de activación y función de coste

- **Capas ocultas: ReLU**. Evita el problema de *vanishing gradient* (frente a sigmoid/tanh), computacionalmente eficiente y empíricamente superior en clasificación tabular.
- **Capa de salida: sigmoid**. Produce una salida en $[0, 1]$ interpretable directamente como $P(\text{impago})$.
- **Función de coste: Binary Cross-Entropy (BCE)** con *class weights*. BCE es la pérdida natural para distribuciones de Bernoulli. Los class weights compensan el desbalanceo sin alterar la probabilidad de las predicciones.

4.3. Capas custom

4.3.1. DebtRatioLayer

Aplica una saturación sigmoide aprendible al ratio de endeudamiento:

$$f(x) = \sigma(\alpha \cdot (x - \theta)), \quad \alpha > 0, \quad \theta \in \mathbb{R} \quad (1)$$

donde α controla la pendiente de la saturación (inicializado en 10) y θ es el umbral de inflexión (inicializado en 0.35, referencia regulatoria del 35 %). Ambos son **parámetros aprendibles**.

La justificación no es predictiva sino **regulatoria**: un ratio de 0.8 y uno de 1.5 son ambos “imposible pagar”; la sigmoide garantiza que el modelo los trate de forma similar, incrustando esta restricción de dominio en la arquitectura.

4.3.2. ExtSourceLayer

Combina las tres fuentes externas en un índice de confianza ponderado:

$$g(\mathbf{s}) = \sigma(w_1 s_1 + w_2 s_2 + w_3 s_3 + b), \quad w_i \geq 0 \quad (2)$$

Los pesos w_i están restringidos a ser no negativos (la relación con el impago es monotóna decreciente, confirmada por los deciles del EDA). Esto hace el modelo **auditable**: tras el entrenamiento, los pesos aprendidos revelan la importancia relativa que el modelo asignó a cada fuente externa.

4.4. Progresión de modelos

Cuadro 4: Comparativa de modelos entrenados (AUC en test, clase 1 ponderada 11.4×).

Modelo	Arquitectura	AUC val	AUC test	Paráms
M0	Reg. Logística (0 capas ocultas)	0.7275	0.7335	13
M1	MLP (Dense 64, ReLU)	0.7416	0.7449	897
M2	MLP (Dense 128→64, ReLU)	0.7411	0.7447	9985
M3	M2 + Dropout(0.3, 0.2)	0.7424	0.7452	9985
M4	M3 + DebtRatioLayer	0.7424	0.7449	9988
M5	M4 + ReduceLROnPlateau	0.7428	0.7449	9988
M6	M5 + ExtSourceLayer (Dual Custom)	0.7421	0.7451	9991




Figura 8: Curvas de entrenamiento y validación (selección representativa). El modelo base (M0) converge más lento y a menor AUC. M6 muestra convergencia suave con *early stopping* efectivo.




Figura 9: Arquitectura del modelo M6 (Dual Custom + Dropout). Las dos ramas paralelas (DebtRatioLayer y ExtSourceLayer) se concatenan con la salida de las capas densas antes de la neurona de clasificación.

Justificación de la profundidad. El análisis de deciles (Figura 5) reveló que **AMT_CREDIT** y **AMT_ANNUITY** presentan una relación en forma de **joroba** con la tasa de impago: los créditos medios tienen mayor tasa que los muy bajos o los muy altos. Una sola capa ReLU (lineal por partes con una única inflexión) no puede capturar este máximo interior; se requieren al menos dos capas ocultas.

El hexbin (Figura 7) muestra además un **efecto de interacción** entre **EXT_SOURCE_2** y **EXT_SOURCE_3** que tampoco es modelable linealmente.

5. Aprendizaje Justo — FAIR Loss

5.1. Formulación

La función de coste customizada combina el error de clasificación con una penalización por **Paridad Demográfica (DP)**:

$$\mathcal{L}_{\text{fair}} = \underbrace{\text{BCE}(y, \hat{y})}_{\text{clasificación}} + \lambda \cdot \underbrace{\left| \mathbb{E}[\hat{y} \mid G = M] - \mathbb{E}[\hat{y} \mid G = F] \right|}_{\text{penalización DP}} \quad (3)$$

5.2. Justificación de la métrica de equidad

Cuadro 5: Comparativa de métricas de equidad consideradas.

Métrica	Diferenciable	Requiere y_{true}	Decisión
Paridad Demográfica (DP)	✓	No	Seleccionada
Equalized Odds	Parcial	Sí	Descartada (complica el grafo)
Mutual Information	×	No	Descartada (no diferenciable)
Correlación $ \text{Corr}(\hat{y}, G) $	✓	No	Descartada (solo lineal)

La DP mide si la tasa de aprobación predicha es similar entre grupos demográficos, que es el requisito regulatorio explícito en la Directiva Europea de IA y la ECOA (Equal Credit Opportunity Act).

5.3. Curva de Pareto




Figura 10: Izquierda: curva de Pareto entre AUC (precisión) y DP Gap (discriminación). Cada punto corresponde a un valor de λ . Derecha: evolución de la predicción media por género al aumentar λ . Las líneas convergen hacia un valor similar, indicando que el modelo aprende a no discriminar.

Cuadro 6: Resultados del experimento Pareto (evaluación en test).

λ	AUC test	DP Gap	$\hat{p}(M)$	$\hat{p}(F)$	ΔAUC
0.0	0.7463	0.0300	0.0998	0.0697	0.0000
0.1	0.7440	0.0079	0.0842	0.0763	-0.0023
0.5	0.7429	0.0034	0.0800	0.0766	-0.0034
1.0	0.7425	0.0044	0.0850	0.0805	-0.0038
2.0	0.7402	0.0023	0.0756	0.0732	-0.0060
5.0	0.7352	0.0019	0.0733	0.0714	-0.0110

Modelo recomendado: $\lambda = 0,5$. De $\lambda = 0$ a $\lambda = 0,5$ el DP Gap se reduce un **89 %** (de 0.0300 a 0.0034) sacrificando únicamente **0.0034 puntos de AUC**. A partir de $\lambda = 0,5$ se produce un rendimiento decreciente: la ganancia en equidad es mínima mientras el coste en AUC se acelera.

6. Incertidumbre — MC Dropout

6.1. Método seleccionado

Se utiliza **Monte Carlo Dropout** (Gal & Ghahramani, 2016), que mantiene activas las capas Dropout durante la inferencia y realiza $N = 100$ pasadas hacia adelante por muestra. La varianza entre pasadas mide la incertidumbre epistémica del modelo:

$$\hat{\sigma}_i^2 = \frac{1}{N} \sum_{t=1}^N (\hat{y}_i^{(t)} - \bar{y}_i)^2, \quad \bar{y}_i = \frac{1}{N} \sum_{t=1}^N \hat{y}_i^{(t)} \quad (4)$$

La elección de MC Dropout frente a alternativas (Redes Bayesianas, Deep Ensembles) se justifica porque M6 ya incorpora capas Dropout: no requiere rediseño arquitectónico y su fundamento teórico como aproximación variacional bayesiana está bien establecido.

6.2. Distribución de incertidumbre por clase




Figura 11: Distribución de la varianza MC Dropout por clase TARGET. M6 base (izq.) muestra distribuciones casi idénticas entre clases: no reconoce que los impagos son más difíciles de predecir. FAIR $\lambda = 0,5$ (dcha.) presenta una cola más larga para TARGET=1, indicando mayor incertidumbre en la clase de riesgo.

6.3. Incertidumbre vs calidad de EXT_SOURCE




Figura 12: Varianza media en función del número de fuentes externas ausentes (imputadas con la mediana). El modelo FAIR muestra un patrón **monótono creciente** (hasta +73 % con las tres fuentes imputadas), mientras que M6 base es prácticamente plano.

6.4. Resultados

Cuadro 7: Resumen de métricas de incertidumbre (test, $N = 100$ pasadas MC Dropout).

Métrica	M6 base	FAIR $\lambda = 0,5$
AUC predicción puntual	0.7451	0.7429
AUC media MC Dropout	0.7455	0.7433
Varianza media — TARGET=0 (pagó)	0.001422	0.000147
Varianza media — TARGET=1 (impago)	0.001306	0.000364
Ratio var(T=1)/var(T=0)	0.92 (−8 %)	2.48 (+148 %)
Varianza — 0 EXT_SOURCE ausentes	0.001472	0.000163
Varianza — 1 EXT_SOURCE ausente	0.001354	0.000161
Varianza — 2 EXT_SOURCE ausentes	0.001489	0.000185
Varianza — 3 EXT_SOURCE ausentes	0.001414	0.000282

Hallazgos clave.

1. **M6 base no distingue incertidumbre por clase:** la varianza en impagos es un 8 % *menor* que en buenos pagadores, comportamiento opuesto al deseable.
2. **FAIR $\lambda = 0,5$ muestra calibración superior:** la varianza en impagos es 2.5× mayor que en buenos pagadores. El modelo reconoce que la clase minoritaria es más difícil.
3. **FAIR detecta degradación por datos imputados:** la varianza crece monótonamente con el número de fuentes externas ausentes (+73 % con las tres imputadas).

4. **MC-mean mejora el AUC:** la media de 100 pasadas supera ligeramente a la predicción puntual en ambos modelos (+0.0004), confirmando el efecto ensemble del MC Dropout.

La restricción de fairness, además de reducir la discriminación demográfica, produce un modelo **más honesto respecto a sus limitaciones de información**: es más incierto cuando no tiene datos de calidad.

7. Conclusiones

Cuadro 8: Comparativa final: modelo base vs mejor modelo FAIR (test).

Métrica	M6 base	FAIR $\lambda = 0,5$
AUC-ROC (test)	0.7451	0.7429
DP Gap	0.0300	0.0034
$\hat{p}(\text{impago} \mid H)$	0.0998	0.0800
$\hat{p}(\text{impago} \mid M)$	0.0697	0.0766
Varianza ratio T1/T0	0.92 (peor)	2.48 (mejor)

El sistema desarrollado alcanza un AUC de 0.745 con el subconjunto de 12 features seleccionadas. La introducción de la FAIR Loss con $\lambda = 0,5$ reduce la discriminación demográfica un 89 % (de 0.030 a 0.003 de DP Gap) con un coste de solo 0.003 puntos de AUC, un tradeoff favorable desde el punto de vista regulatorio.

El análisis de incertidumbre mediante MC Dropout revela que el modelo FAIR es intrínsecamente más honesto: reconoce cuándo trabaja con información de baja calidad (fuentes externas imputadas) y cuándo enfrenta la clase de mayor riesgo (impago), aumentando su varianza de predicción en ambos casos.